TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN VÀ TRUYỀN THÔNG

KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO TIỂU LUẬN

HỌC PHẦN: HỌC MÁY

ĐỀ TÀI:

DỰ ĐOÁN XU HƯỚNG TĂNG/GIẢM GIÁ CỔ PHIẾU

Giảng viên hướng dẫn: TS. Nguyễn Tuấn Anh

Lớp học phần: CNTT K22H + CNTT K22G

Nhóm thực hiện: Nhóm 16

Trần Văn Hiếu – DTC235200278

Hoàng Đức Toàn – DTC235200752

Thái Nguyên, tháng 12 năm 2026

NHẬN XÉT CỦA GIẢNG VIÊN

1. Về hình thức và bố cục báo cáo:

. . . . . .

. . . . . .

. . . . . .

2. Về nội dung và kết quả thực hiện:

. . . . . .

. . . . . .

. . . . . .

. . . . . .

. . . . . .

3. Về tinh thần, thái độ làm việc của nhóm:

. . . . . .

. . . . . .

. . . . . .

4. Điểm đánh giá:

STT	Họ và tên sinh viên	Điểm số	Điểm chữ
1	Trần Văn Hiếu		
2	Hoàng Đức Toàn		

Thái Nguyên, ngày ... tháng ... năm ...

Giảng viên

(Ký và ghi rõ họ tên)

TS. Nguyễn Tuấn Anh

LỜI CAM ĐOAN

Chúng em xin cam đoan báo cáo tiểu luận "*DỰ ĐOÁN XU HƯỚNG TĂNG/GIẢM GIÁ CỔ PHIẾU*" là kết quả làm việc của nhóm dưới sự hướng dẫn của giảng viên TS. Nguyễn Tuấn Anh. Các số liệu, kết quả thực nghiệm trình bày trong báo cáo là trung thực, được tạo ra từ mã nguồn của nhóm và có thể chạy lại được. Mọi tài liệu, mã nguồn, dữ liệu tham khảo đều được trích dẫn đầy đủ trong danh mục tài liệu tham khảo.

Khai báo sử dụng công cụ AI tạo sinh. Nhóm sử dụng các công cụ AI tạo sinh **Claude** (Anthropic) và **Codex** (OpenAI) trong các phạm vi sau:

- gợi ý ý tưởng về hướng tiếp cận, đặc trưng và cách đánh giá mô hình;
- sửa lỗi mã nguồn;
- viết tài liệu và nội dung báo cáo;
- hỗ trợ xử lý dữ liệu (làm sạch dữ liệu, tạo đặc trưng và nhãn).

Nhóm đã kiểm tra, chạy lại và chịu trách nhiệm về toàn bộ nội dung, mã nguồn và số liệu trong báo cáo; mỗi thành viên giải thích được mọi đoạn mã và nội dung đã nộp.

Nếu phát hiện có bất kỳ sự gian lận nào, chúng em xin hoàn toàn chịu trách nhiệm trước giảng viên và nhà trường.

Thái Nguyên, ngày ... tháng ... năm ...

Nhóm sinh viên thực hiện

(Ký và ghi rõ họ tên)

Trần Văn Hiếu Hoàng Đức Toàn

LỜI CẢM ƠN

Trong quá trình thực hiện đề tài "*DỰ ĐOÁN XU HƯỚNG TĂNG/GIẢM GIÁ CỔ PHIẾU*", nhóm đã nhận được sự hướng dẫn và giúp đỡ của nhiều cá nhân và tổ chức.

Trước hết, chúng em xin bày tỏ lòng biết ơn sâu sắc đến giảng viên TS. Nguyễn Tuấn Anh, người đã giảng dạy học phần Học máy, định hướng đề tài và góp ý cho nhóm trong từng giai đoạn của dự án. Những nhận xét của thầy giúp chúng em hiểu rõ hơn về quy trình xây dựng và đánh giá một mô hình học máy đúng phương pháp.

Chúng em xin cảm ơn Khoa Công nghệ Thông tin và quý thầy cô Trường Đại học Công nghệ Thông tin và Truyền thông đã tạo điều kiện học tập và cung cấp nền tảng kiến thức để nhóm hoàn thành báo cáo. Chúng em cũng cảm ơn DNSE (Entrade) đã cung cấp dữ liệu giá lịch sử công khai, là nguồn dữ liệu cho thực nghiệm của đề tài.

Do kiến thức và thời gian có hạn, báo cáo khó tránh khỏi thiếu sót. Nhóm rất mong nhận được ý kiến đóng góp của thầy cô để báo cáo được hoàn thiện hơn.

Chúng em xin chân thành cảm ơn!

Nhóm sinh viên thực hiện

MỤC LỤC

LỜI CAM ĐOAN . . . . . **ii**

LỜI CẢM ƠN . . . . . **iii**

DANH MỤC HÌNH ẢNH . . . . . **vii**

DANH MỤC BẢNG . . . . . **viii**

DANH MỤC TỪ VIẾT TẮT . . . . . **ix**

MỞ ĐẦU **1**

Chương 1. Tổng quan về học máy và bài toán dự đoán xu hướng giá cổ phiếu 3

1.1. Giới thiệu bài toán 3

1.2. Các công trình nghiên cứu liên quan 3

1.3. Đặc điểm chuỗi giá cổ phiếu và các chỉ báo kỹ thuật 4

1.3.1. Đặc điểm chuỗi giá cổ phiếu 4

1.3.2. Các chỉ báo kỹ thuật 5

1.4. Cơ sở lý thuyết các thuật toán sử dụng 6

1.4.1. Thuật toán 1: Hồi quy Logistic 6

1.4.2. Thuật toán 2: Rừng ngẫu nhiên 6

1.4.3. Thuật toán 3: XGBoost 6

1.5. Các chỉ số đánh giá mô hình 7

1.6. Kết luận chương 1 7

Chương 2. Mô hình hóa bài toán và phương pháp dự đoán xu hướng giá cổ phiếu **9**

2.1. Phát biểu bài toán học máy 9

2.2. Mục tiêu và tiêu chí thành công 9

2.3. Lựa chọn thuật toán và mô hình cơ sở 10

2.3.1. Lựa chọn thuật toán 10

2.3.2. Mô hình cơ sở 11

2.4. Quy trình huấn luyện 11

2.5. Phương pháp và chỉ số đánh giá 12
2.6. Kết luận chương 2 13
Chương 3. Thực nghiệm và đánh giá 14
3.1. Dữ liệu thực nghiệm 14
3.1.1. Nguồn dữ liệu 14
3.1.2. Từ điển dữ liệu thô 15
3.2. Khảo sát và phân tích dữ liệu 18
3.2.1. Biến động giá và khối lượng theo thời gian 18
3.2.2. Phân bố lợi suất ngày 19
3.2.3. Phân bố nhãn xu hướng 20
3.2.4. Tự tương quan của chuỗi lợi suất 20
3.2.5. Quan hệ tương quan giữa các đặc trưng 21
3.2.6. Phân bố các đặc trưng chính theo nhãn xu hướng 23
3.3. Phát hiện và xử lý vấn đề chất lượng dữ liệu 24
3.4. Chuẩn bị dữ liệu cho mô hình 25
3.5. Môi trường thực nghiệm 27
3.6. Kết quả huấn luyện và đánh giá 28
3.7. Phân tích kết quả dự đoán 29
3.8. Tối ưu hóa và cải tiến mô hình 29
3.8.1. Phân tích hạn chế của mô hình ban đầu 29
3.8.2. Cải tiến dữ liệu và đặc trưng 30
3.8.3. Thử nghiệm thuật toán hoặc cấu hình khác 30
3.8.4. Tối ưu hóa siêu tham số 30
3.9. So sánh trước và sau cải tiến 30
3.10. Khả năng tổng quát hóa và lựa chọn mô hình cuối 31
3.10.1. Khả năng tổng quát hóa 31
3.10.2. Lựa chọn mô hình cuối cùng 31
3.11. Kết luận chương 3 31
KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 32
TÀI LIỆU THAM KHẢO 33

Phụ lục A. Hướng dẫn cài đặt và chạy chương trình 35
A.1. Yêu cầu môi trường 35
A.2. Các bước thực hiện 35

DANH MỤC HÌNH ẢNH

Hình 1.1. Quy trình thực hiện dự án học máy 3

Hình 2.1. Kiểm định walk-forward với cửa sổ huấn luyện mở rộng. 12

Hình 3.1. Giá đóng cửa và khối lượng giao dịch ngày của bốn mã cổ phiếu. 18

Hình 3.2. Phân bố tần suất lợi suất logarit ngày của bốn mã 19

Hình 3.3. Số lượng và tỷ lệ phân bố ba lớp nhãn ($\theta = 0{,}5\%$) sau tiền xử lý 20

Hình 3.4. Hàm tự tương quan (ACF) của lợi suất ngày đến lag 20 kèm dải tin cậy 95%. 21

Hình 3.5. Ma trận tương quan Pearson giữa 25 đặc trưng số (gộp 4 mã) 22

Hình 3.6. Phân bố 6 đặc trưng đại diện theo ba lớp nhãn xu hướng (gộp 4 mã) . . . 23

Hình 3.7. Minh họa các fold kiểm định walk-forward thực tế trên mã CTG (27 fold). 26

Hình 3.8. Ma trận nhầm lẫn của mô hình tốt nhất trên tập kiểm định. 29

Hình 3.9. Đường cong học tập của mô hình ban đầu 30

Hình 3.10. So sánh chỉ số đánh giá của các mô hình trước và sau cải tiến 31

DANH MỤC BẢNG

Bảng 2.1. Mục tiêu và chỉ số đánh giá 10

Bảng 3.1. Phạm vi dữ liệu nến ngày thô của bốn mã 14

Bảng 3.2. Từ điển dữ liệu thô (mỗi dòng là một nến ngày) 15

Bảng 3.3. Từ điển 25 đặc trưng sau tiền xử lý 15

Bảng 3.4. Thống kê các vấn đề chất lượng dữ liệu và cách xử lý 24

Bảng 3.5. So sánh số nến trước và sau làm sạch dữ liệu 1D 25

Bảng 3.6. Kích thước dữ liệu đã tiền xử lý và số fold walk-forward 26

Bảng 3.7. Quy tắc và kết quả tiền xử lý theo khung nến 27

Bảng 3.8. Môi trường thực nghiệm phần cứng và phần mềm 28

Bảng 3.9. So sánh kết quả kiểm định walk-forward của các mô hình 29

Bảng 3.10. Không gian tìm kiếm và giá trị siêu tham số tối ưu 30

Bảng 3.11. Đóng góp của từng cải tiến (ablation) 31

DANH MỤC TỪ VIẾT TẮT

STT	Viết tắt	Ý nghĩa
1	AUC	Area Under the Curve – Diện tích dưới đường cong ROC
2	CV	Cross-Validation – Kiểm định chéo
3	EDA	Exploratory Data Analysis – Phân tích khám phá dữ liệu
4	KNN	K-Nearest Neighbors – K láng giềng gần nhất
5	ML	Machine Learning – Học máy
6	RF	Random Forest – Rừng ngẫu nhiên
7	RMSE	Root Mean Squared Error – Căn bậc hai sai số bình phương trung bình
8	ROC	Receiver Operating Characteristic
9	SVM	Support Vector Machine – Máy vectơ hỗ trợ

MỞ ĐẦU

1. Lý do chọn đề tài

Giá cổ phiếu là chuỗi thời gian chịu tác động của nhiều yếu tố và có nhiễu lớn. Các chỉ báo kỹ thuật như đường trung bình động (SMA, EMA), chỉ số sức mạnh tương đối (RSI), MACD và dải Bollinger được nhà đầu tư dùng rộng rãi để nhận diện xu hướng, nhưng việc đọc chúng phụ thuộc vào kinh nghiệm cá nhân. Học máy cho phép kết hợp đồng thời nhiều chỉ báo và đo được một cách khách quan mức độ hữu ích của chúng thông qua các chỉ số phân loại và kết quả mô phỏng giao dịch.

Đề tài còn có ý nghĩa về phương pháp luận: dự đoán giá cổ phiếu là bài toán mà việc đánh giá sai cách (xáo trộn dữ liệu theo thời gian, rò rỉ thông tin từ tương lai) rất dễ cho ra kết quả đẹp nhưng không có giá trị. Vì vậy đề tài là cơ hội để thực hành kiểm định theo thời gian (walk-forward) và thảo luận trung thực về giới hạn của việc dự đoán giá.

2. Mục tiêu và nhiệm vụ

Mục tiêu tổng quát: xây dựng và đánh giá các mô hình học máy dự đoán xu hướng (tăng, ngang, giảm) của giá đóng cửa phiên giao dịch kế tiếp cho bốn mã cổ phiếu TCB, CTG, VNM, ACB trên sàn chứng khoán Việt Nam, và so sánh với các chiến lược cơ sở.

Các nhiệm vụ chính:

(1) Nghiên cứu đặc điểm chuỗi giá cổ phiếu và các chỉ báo kỹ thuật (SMA, EMA, RSI, MACD, Bollinger Bands); phát biểu bài toán phân loại xu hướng.

(2) Thu thập dữ liệu giá lịch sử của bốn mã và tính các chỉ báo kỹ thuật làm đặc trưng.

(3) Huấn luyện Hồi quy Logistic, Rừng ngẫu nhiên, XGBoost với kiểm định walk-forward; so sánh với chiến lược mua và nắm giữ, dự đoán ngẫu nhiên.

(4) Đánh giá bằng Accuracy, F1, ROC-AUC và lợi nhuận mô phỏng (backtest đơn giản); thảo luận giới hạn của việc dự đoán giá và nguy cơ quá khớp.

3. Đối tượng và phạm vi nghiên cứu

Đối tượng: dữ liệu nến ngày (OHLCV) của bốn cổ phiếu ngân hàng và tiêu dùng niêm yết trên thị trường Việt Nam: TCB, CTG, ACB và VNM.

Phạm vi: khung nến chính là 1 ngày, dùng toàn bộ lịch sử có thể lấy được (khoảng 8–10 năm, đến ngày 23/10/2026); mỗi mã được huấn luyện một mô hình riêng. Đề tài chỉ xét dự đoán một phiên phía trước dựa trên dữ liệu giá và khối lượng, không dùng tin tức, báo cáo tài chính hay dữ liệu vĩ mô. Khung nến 1 giờ là phần mở rộng nếu còn thời gian.

4. Phương pháp thực hiện

Dữ liệu nến được thu thập bằng mã Python từ API biểu đồ của DNSE (Entrade), làm sạch, tính 25 đặc trưng kỹ thuật và gán nhãn theo lợi suất của phiên kế tiếp. Các mô hình Hồi quy Logistic, Rừng ngẫu nhiên và XGBoost được huấn luyện và đánh giá bằng walk-forward với cửa sổ mở rộng, thang đo Accuracy, F1 (macro), ROC-AUC (một-đối-còn-lại, macro) và backtest chỉ mua. Công cụ sử dụng: Python, Pandas, NumPy, Scikit-learn, XGBoost.

5. Bố cục báo cáo

Ngoài phần Mở đầu, Kết luận, Tài liệu tham khảo và Phụ lục, báo cáo gồm 3 chương:

- **Chương 1. Tổng quan về học máy và bài toán dự đoán xu hướng giá cổ phiếu:** trình bày bài toán, các công trình liên quan và cơ sở lý thuyết của các thuật toán sử dụng.
- **Chương 2. Mô hình hóa bài toán và phương pháp dự đoán xu hướng giá cổ phiếu:** phát biểu bài toán, mục tiêu, lựa chọn thuật toán, mô hình cơ sở, quy trình huấn luyện và phương pháp đánh giá.
- **Chương 3. Thực nghiệm và đánh giá:** dữ liệu thực nghiệm (mô tả, khảo sát, tiền xử lý), kết quả huấn luyện, phân tích, tối ưu và cải tiến, lựa chọn mô hình cuối cùng.

CHƯƠNG 1

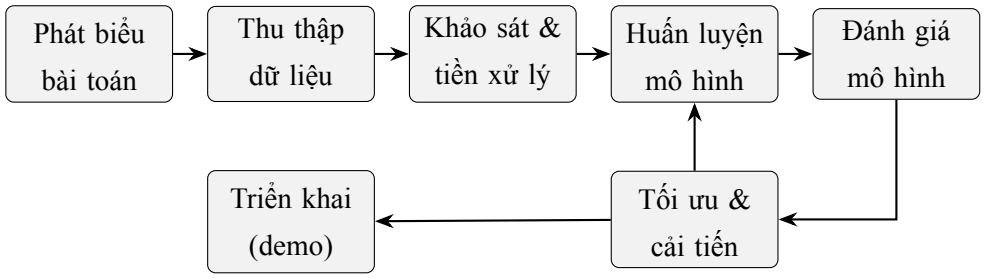
TỔNG QUAN VỀ HỌC MÁY VÀ BÀI TOÁN DỰ ĐOÁN XU HƯỚNG GIÁ CỔ PHIẾU

1.1. Giới thiệu bài toán

Dự đoán xu hướng giá cổ phiếu là bài toán xác định, tại cuối mỗi phiên giao dịch, giá đóng cửa của phiên kế tiếp sẽ tăng, giảm hay đi ngang. Kết quả có thể được nhà đầu tư cá nhân dùng như một tín hiệu tham khảo bên cạnh phân tích của họ, hoặc được dùng để mô phỏng một chiến lược giao dịch đơn giản. Thay vì dự đoán chính xác mức giá (bài toán hồi quy rất nhạy với nhiễu), đề tài chuyển về bài toán phân loại hướng biến động, phù hợp hơn với việc ra quyết định mua, giữ hoặc bán.

Với thị trường Việt Nam, nhà đầu tư không được bán khống cổ phiếu, nên tín hiệu hữu ích nhất là biết khi nào nên nắm giữ và khi nào nên đứng ngoài. Điều này được phản ánh trong cách mô phỏng giao dịch ở Chương 3.

Quy trình thực hiện dự án học máy của nhóm được mô tả tổng quát trong Hình 1.1.



Hình 1.1. Quy trình thực hiện dự án học máy

1.2. Các công trình nghiên cứu liên quan

Dự đoán hướng biến động giá bằng chỉ báo kỹ thuật và học máy đã được nghiên cứu nhiều trên các thị trường khác nhau. Theo phần tóm tắt của các tác giả:

- Kara và cộng sự [7] dự đoán hướng biến động hằng ngày của chỉ số Istanbul Stock Exchange National 100 bằng mạng nơ-ron nhân tạo và SVM với 10 chỉ báo kỹ thuật làm đầu vào; độ chính xác trung bình của mạng nơ-ron đạt khoảng 75,74%, của SVM khoảng 71,52%.

- Patel và cộng sự [10] dùng 10 tham số kỹ thuật tính từ giá mở cửa, cao nhất, thấp nhất, đóng cửa của hai cổ phiếu (Reliance Industries, Infosys) và hai chỉ số (CNX Nifty, S&P BSE Sensex) của Ấn Độ giai đoạn 2003–2012, với các mô hình Naive Bayes, mạng nơ-ron, SVM và Rừng ngẫu nhiên. Kết quả cho thấy hiệu năng của cả bốn mô hình đều tăng khi các tham số kỹ thuật được biểu diễn dưới dạng "xu hướng xác định" (trend deterministic).
- Krauss và cộng sự [8] so sánh mạng nơ-ron sâu, cây tăng cường độ dốc, rừng ngẫu nhiên và các tổ hợp của chúng trên các cổ phiếu thuộc S&P 500 (1992–2015), đầu vào là lợi suất các phiên trước. Tổ hợp đơn giản của ba mô hình cho lợi suất trên 0,45% mỗi ngày (với $k = 10$) trước chi phí giao dịch; tuy nhiên lợi nhuận giảm dần và có lúc âm ở các năm cuối của mẫu.
- Trương Thị Thùy Dương [1] dự báo chiều biến động của VN-Index bằng XGBoost với giá đóng cửa và các chỉ báo kỹ thuật; kết quả báo cáo có độ chính xác trên 80% và khối lượng giao dịch là đặc trưng quan trọng nhất.

Các công trình trên khác nhau về bài toán (hai lớp hay nhiều lớp), đối tượng (chỉ số hay cổ phiếu riêng lẻ) và cách chia dữ liệu, nên con số độ chính xác không thể so sánh trực tiếp với kết quả của đề tài. Kết quả của Krauss và cộng sự cho thấy lợi thế dự đoán có thể suy giảm theo thời gian, nên việc đánh giá cần dựa trên kiểm định theo thứ tự thời gian [2, 9].

Điểm khác của đề tài so với các công trình trên là: (i) bài toán ba lớp (giảm, ngang, tăng) với ngưỡng θ gắn với chi phí giao dịch; (ii) kiểm định walk-forward có bỏ một phiên giữa tập huấn luyện và tập kiểm tra để tránh rò rỉ nhãn; (iii) so sánh với chiến lược cơ sở (mua và nắm giữ, dự đoán ngẫu nhiên); (iv) mô phỏng giao dịch chỉ mua có tính phí và thuế; (v) đối tượng là bốn cổ phiếu riêng lẻ của thị trường Việt Nam, mỗi mã một mô hình riêng.

1.3. Đặc điểm chuỗi giá cổ phiếu và các chỉ báo kỹ thuật

1.3.1. Đặc điểm chuỗi giá cổ phiếu

Giá đóng cửa C_t là chuỗi thời gian không dừng: mức giá và độ biến động thay đổi theo thời gian, nên mô hình học trực tiếp trên giá thô dễ học theo mức giá thay vì hình thái biến động. Vì vậy đề tài dùng lợi suất logarit $r_t = \ln(C_t/C_{t-1})$ và các đặc trưng được chuẩn hóa về dạng tỷ lệ so với giá.

Lợi suất ngày của bốn mã có độ lệch chuẩn 1,5–2,1%, trong khi mức dịch chuyển trung bình rất nhỏ, nghĩa là tỷ lệ tín hiệu trên nhiễu thấp. Giá còn bị giới hạn bởi biên độ giao dịch trong ngày (khoảng $\pm 7\%$ trên HOSE và $\pm 10\%$ trên HNX). Theo giả thuyết thị trường hiệu quả [5], giá đã phản ánh thông tin sẵn có nên rất khó dự đoán; do đó nhóm đặt kỳ vọng ở mức thực tế: mô hình chỉ cần vượt các mức tham chiếu một cách có ý nghĩa, không đặt mục tiêu độ chính xác cao.

1.3.2. Các chỉ báo kỹ thuật

Các chỉ báo dưới đây được tính từ giá đóng cửa C_t (và độ lệch chuẩn σ) và là nhóm đặc trưng lõi của đề tài.

Đường trung bình động đơn giản (SMA) làm mượt giá trên n phiên:

$$\mathrm{SMA}_n(t) = \frac{1}{n} \sum_{i=0}^{n-1} C_{t-i}. \tag{1.1}$$

Giá nằm trên SMA thường được xem là xu hướng tăng; giao cắt giữa SMA ngắn hạn và dài hạn là tín hiệu đổi xu hướng.

Đường trung bình động hàm mũ (EMA) đặt trọng số lớn hơn cho các phiên gần đây:

$$\mathrm{EMA}_n(t) = \alpha C_t + (1-\alpha)\,\mathrm{EMA}_n(t-1), \qquad \alpha = \frac{2}{n+1}. \tag{1.2}$$

MACD đo chênh lệch giữa hai EMA, kèm đường tín hiệu và biểu đồ cột:

$$\begin{aligned} \mathrm{MACD} &= \mathrm{EMA}_{12} - \mathrm{EMA}_{26}, \\ \mathrm{Signal} &= \mathrm{EMA}_9(\mathrm{MACD}), \\ \mathrm{Hist} &= \mathrm{MACD} - \mathrm{Signal}. \end{aligned} \tag{1.3}$$

Chỉ số sức mạnh tương đối (RSI) [12] đo tương quan giữa mức tăng và mức giảm trung bình trong $n = 14$ phiên (làm mượt theo Wilder):

$$\mathrm{RSI} = 100 - \frac{100}{1 + \mathrm{RS}}, \qquad \mathrm{RS} = \frac{\text{mức tăng trung bình}}{\text{mức giảm trung bình}}. \tag{1.4}$$

RSI cao (thường trên 70) gợi ý trạng thái mua quá mức, thấp (dưới 30) gợi ý bán quá mức.

Dải Bollinger gồm đường giữa SMA_{20} và hai dải cách 2σ:

$$\text{BB}_{\pm} = \text{SMA}_{20} \pm 2\sigma_{20}, \qquad \%B = \frac{C_t - \text{BB}_-}{\text{BB}_+ - \text{BB}_-}. \tag{1.5}$$

Chỉ số $\%B$ cho biết giá nằm ở đâu trong dải, độ rộng dải phản ánh mức biến động.

1.4. Cơ sở lý thuyết các thuật toán sử dụng

1.4.1. Thuật toán 1: Hồi quy Logistic

Với bài toán $K = 3$ lớp, hồi quy Logistic (dạng đa thức, hàm softmax) ước lượng xác suất mẫu **x** thuộc lớp k [6]:

$$P(y = k \mid \mathbf{x}) = \frac{e^{\mathbf{w}_k^\top \mathbf{x} + b_k}}{\sum_{j=1}^{K} e^{\mathbf{w}_j^\top \mathbf{x} + b_j}}. \tag{1.6}$$

Tham số được chọn để cực tiểu hóa hàm mất mát entropy chéo có điều chuẩn L_2:

$$\min_{W,\mathbf{b}} \; -\sum_{i=1}^{N} \ln P(y_i \mid \mathbf{x}_i) + \frac{1}{2C} \|W\|_2^2. \tag{1.7}$$

Siêu tham số chính là C: C nhỏ điều chuẩn mạnh (mô hình đơn giản, ít quá khớp), C lớn điều chuẩn yếu. Mô hình tuyến tính, dễ diễn giải và cần chuẩn hóa đặc trưng.

1.4.2. Thuật toán 2: Rừng ngẫu nhiên

Rừng ngẫu nhiên [3] kết hợp nhiều cây quyết định, mỗi cây được huấn luyện trên một mẫu bootstrap của tập huấn luyện và tại mỗi nút chỉ xét một tập con ngẫu nhiên các đặc trưng. Mỗi cây chọn phép tách làm giảm nhiều nhất độ tạp Gini $G = 1 - \sum_k p_k^2$; dự đoán cuối là trung bình xác suất lớp của các cây. Việc lấy trung bình nhiều cây tương quan thấp làm giảm phương sai và hạn chế quá khớp. Các siêu tham số chính: số cây (`n_estimators`), độ sâu tối đa (`max_depth`), số mẫu tối thiểu ở lá (`min_samples_leaf`) và số đặc trưng xét tại mỗi nút (`max_features`).

1.4.3. Thuật toán 3: XGBoost

XGBoost [4] là thuật toán tăng cường độ dốc (gradient boosting) trên cây quyết định: các cây được thêm lần lượt, mỗi cây sửa sai số của tổ hợp trước. Hàm mục tiêu

gồm mất mát và phạt độ phức tạp của cây:

$$\mathcal{L} = \sum_{i=1}^{N} \ell(y_i, \hat{y}_i) + \sum_{m} \Omega(f_m), \qquad \Omega(f) = \gamma T + \tfrac{1}{2}\lambda \|\mathbf{w}\|^2, \tag{1.8}$$

trong đó T là số lá và $\mathbf{w}$ là trọng số các lá; với $K = 3$ lớp mất mát ℓ là entropy chéo softmax. Các siêu tham số chính: số cây, tốc độ học η, độ sâu tối đa, tỷ lệ lấy mẫu hàng và cột (`subsample`, `colsample_bytree`) và hệ số điều chuẩn λ, γ. XGBoost yêu cầu nhãn là $0, 1, 2$ nên nhãn $\{-1, 0, 1\}$ được ánh xạ thành $y + 1$ khi huấn luyện.

1.5. Các chỉ số đánh giá mô hình

Với bài toán ba lớp, các chỉ số được tính từ ma trận nhầm lẫn 3×3. Với lớp k, $\text{Precision}_k = \frac{TP_k}{TP_k + FP_k}$, $\text{Recall}_k = \frac{TP_k}{TP_k + FN_k}$ và

$$F_{1,k} = \frac{2\,\text{Precision}_k\,\text{Recall}_k}{\text{Precision}_k + \text{Recall}_k}, \qquad \text{F1 macro} = \frac{1}{3}\sum_{k} F_{1,k}, \tag{1.9}$$

$$\text{Accuracy} = \frac{\text{số mẫu dự đoán đúng}}{\text{tổng số mẫu}}. \tag{1.10}$$

ROC-AUC đo khả năng xếp hạng đúng của xác suất dự đoán, không phụ thuộc ngưỡng quyết định. Với ba lớp, nhóm tính AUC theo cách một-đối-còn-lại cho từng lớp rồi lấy trung bình macro; giá trị $0{,}5$ tương ứng đoán ngẫu nhiên.

Lợi nhuận mô phỏng (backtest). Giữ vị thế $s_t \in \{0, 1\}$ từ đóng cửa phiên t đến đóng cửa phiên $t + 1$: dự đoán 1 thì mua hoặc giữ ($s_t = 1$), dự đoán -1 thì bán và đứng ngoài ($s_t = 0$), dự đoán 0 thì giữ nguyên vị thế. Giá trị danh mục cập nhật theo

$$V_{t+1} = V_t \left(1 + s_t R_{t+1}\right) \cdot (\text{hệ số phí khi đổi vị thế}), \tag{1.11}$$

với $R_{t+1} = e^{r_{t+1}} - 1$; phí giả định là $0{,}15\%$ mỗi chiều và thuế $0{,}1\%$ khi bán. Kết quả được so với chiến lược mua và nắm giữ.

1.6. Kết luận chương 1

Chương này giới thiệu bài toán dự đoán xu hướng giá cổ phiếu, tóm tắt một số công trình liên quan và chỉ ra điểm khác của đề tài. Chương cũng trình bày đặc điểm của chuỗi giá (không dừng, nhiều nhiễu, khó dự đoán), các chỉ báo kỹ thuật SMA, EMA, MACD,

RSI, Bollinger Bands dùng làm đặc trưng, nguyên lý của Hồi quy Logistic, Rừng ngẫu nhiên, XGBoost và các chỉ số đánh giá. Chương 2 sẽ phát biểu bài toán cụ thể, lựa chọn thuật toán, mô hình cơ sở và quy trình huấn luyện.

CHƯƠNG 2

MÔ HÌNH HÓA BÀI TOÁN VÀ PHƯƠNG PHÁP DỰ ĐOÁN XU HƯỚNG GIÁ CỔ PHIẾU

2.1. Phát biểu bài toán học máy

- **Loại bài toán:** phân loại có giám sát, ba lớp, trên dữ liệu chuỗi thời gian.
- **Đơn vị mẫu:** một phiên giao dịch ngày t của một mã cổ phiếu. Mỗi mã có một tập dữ liệu và một mô hình riêng.
- **Đầu vào:** vectơ gồm 25 đặc trưng kỹ thuật tính từ dữ liệu nến đến hết phiên t (các chỉ báo SMA, EMA, MACD, RSI, Bollinger Bands, lợi suất các kỳ trước, hình dạng nến, biến động và khối lượng giao dịch). Không dùng giá thô làm đặc trưng.
- **Đầu ra:** nhãn $y_t \in \{-1, 0, 1\}$ (giảm, ngang, tăng) xác định từ lợi suất logarit của phiên kế tiếp $r_{t+1} = \ln(C_{t+1}/C_t)$, với C_t là giá đóng cửa phiên t và ngưỡng $\theta = 0{,}5\%$:

$$y_t = \begin{cases} 1 & \text{nếu } r_{t+1} > \theta, \\ -1 & \text{nếu } r_{t+1} < -\theta, \\ 0 & \text{còn lại.} \end{cases} \tag{2.1}$$

Ngưỡng $\theta = 0{,}5\%$ được chọn vì độ lệch chuẩn lợi suất ngày của bốn mã là 1,5–2,1%, và với ngưỡng này ba lớp có tỷ lệ gần cân bằng (xem Mục 3.3). Ngưỡng này cũng xấp xỉ chi phí của một vòng mua bán (phí và thuế), nên lớp "ngang" tương ứng với những biến động không đủ để có lãi.

2.2. Mục tiêu và tiêu chí thành công

Mục tiêu thực tế là có một tín hiệu hỗ trợ quyết định mua, giữ hoặc bán. Do giá cổ phiếu chứa nhiều nhiễu, nhóm không đặt mục tiêu độ chính xác cao mà đặt mục tiêu so sánh với các mức tham chiếu: dự đoán ngẫu nhiên (xác suất mỗi lớp khoảng $1/3$) và chiến lược mua và nắm giữ (Bảng 2.1).

Bảng 2.1. Mục tiêu và chỉ số đánh giá

Mục tiêu thực tế	Mục tiêu học máy	Chỉ số chính	Mức tham chiếu
Biết hướng đi của phiên kế tiếp	Phân loại 3 lớp (giảm, ngang, tăng)	F1 macro	Cao hơn dự đoán ngẫu nhiên ($\approx 0{,}33$)
Xếp hạng khả năng tăng/giảm theo xác suất	Xuất xác suất đúng thứ hạng	ROC-AUC macro (một-đối-còn-lại)	Lớn hơn $0{,}50$
Có lãi sau chi phí giao dịch	Backtest chỉ mua theo dự đoán	Lợi nhuận tích lũy	Không thấp hơn mua và nắm giữ trên cùng giai đoạn
Mô hình không quá khớp	Ổn định giữa các fold	Độ lệch chuẩn giữa các fold	Chênh lệch train–test nhỏ

2.3. Lựa chọn thuật toán và mô hình cơ sở

2.3.1. Lựa chọn thuật toán

Dữ liệu của mỗi mã có khoảng 2 000–2 500 mẫu, 25 đặc trưng số, ba lớp gần cân bằng và nhiều nhiễu. Với đặc điểm đó, nhóm chọn ba thuật toán có độ phức tạp tăng dần để quan sát việc tăng độ phức tạp có thực sự giúp ích hay chỉ gây quá khớp:

- **Hồi quy Logistic:** mô hình tuyến tính, ít tham số nên ít quá khớp trên dữ liệu nhỏ và nhiều nhiễu, cho xác suất để tính ROC-AUC, dễ diễn giải hệ số của từng chỉ báo.
- **Rừng ngẫu nhiên:** học được quan hệ phi tuyến và tương tác giữa các chỉ báo, không cần chuẩn hóa đặc trưng, ổn định nhờ lấy trung bình nhiều cây, cho độ quan trọng của đặc trưng để phân tích.
- **XGBoost:** tăng cường độ dốc có điều chuẩn, thường cho kết quả tốt trên dữ liệu dạng bảng cỡ vừa, có nhiều siêu tham số để kiểm soát quá khớp.

SVM cũng là thuật toán được gợi ý; nhóm để dành làm thử nghiệm bổ sung ở giai đoạn cải tiến mô hình (Mục 3.8) nếu còn thời gian.

2.3.2. Mô hình cơ sở

Mô hình cơ sở là các mốc tham chiếu đơn giản mà mô hình học máy phải vượt qua:

- **Lớp đa số:** luôn dự đoán lớp xuất hiện nhiều nhất trong tập huấn luyện của fold.
- **Dự đoán ngẫu nhiên:** chọn lớp theo tỷ lệ lớp trong tập huấn luyện; lặp lại với nhiều giá trị `random_state` khác nhau và lấy trung bình để kết quả không phụ thuộc một lần chạy.
- **Mua và nắm giữ:** mua ở đầu khối kiểm tra và giữ đến hết khối; dùng làm mốc cho phần lợi nhuận mô phỏng.

Kết quả của các mô hình cơ sở được báo cáo cùng các mô hình học máy ở Bảng 3.9.

2.4. Quy trình huấn luyện

Mỗi mã cổ phiếu được huấn luyện riêng với quy trình sau (Hình 2.1):

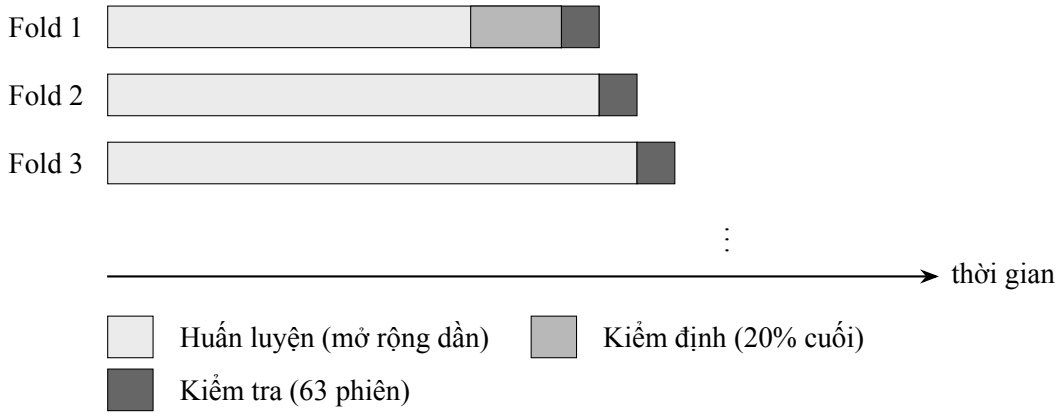
(1) Đọc dữ liệu đã tiền xử lý: ma trận đặc trưng X (25 cột) và nhãn y, sắp xếp theo thời gian.

(2) Chia theo cửa sổ mở rộng (walk-forward): tập huấn luyện ban đầu gồm 750 phiên (khoảng 3 năm), mỗi khối kiểm tra gồm 63 phiên (khoảng một quý), các khối kiểm tra liền nhau và không chồng lấn. Bỏ phiên cuối của tập huấn luyện vì nhãn của nó dùng giá đóng cửa của phiên kiểm tra đầu tiên.

(3) Trong mỗi fold, lấy 20% cuối (theo thời gian) của tập huấn luyện làm tập kiểm định để chọn siêu tham số; sau đó huấn luyện lại trên toàn bộ tập huấn luyện của fold và dự đoán khối kiểm tra. Khối kiểm tra không bao giờ được dùng để chọn bất cứ thứ gì.

(4) Bộ chuẩn hóa `StandardScaler` (cho Hồi quy Logistic) nằm trong `Pipeline` [11] nên luôn được khớp lại trên tập huấn luyện của từng fold; `random_state` cố định là 42.

(5) Gộp dự đoán các khối kiểm tra theo thứ tự thời gian để tính các chỉ số và chạy backtest; báo cáo trung bình $\pm$ độ lệch chuẩn qua các fold.



Hình 2.1. Kiểm định walk-forward với cửa sổ huấn luyện mở rộng

Đoạn mã 2.1 minh họa cách chia fold và Pipeline cho Hồi quy Logistic.

Đoạn mã 2.1. Chia walk-forward và Pipeline (minh họa)

```
import numpy as np
from sklearn.linear_model import LogisticRegression
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler

SEED = 42
TRAIN0, TEST, PURGE = 750, 63, 1

def walk_forward(n):
    for start in range(TRAIN0 + PURGE, n - TEST + 1, TEST):
        yield np.arange(0, start - PURGE), np.arange(start, start + TEST)

mo_hinh = Pipeline([
    ("scaler", StandardScaler()),
    ("clf", LogisticRegression(max_iter=1000, random_state=SEED)),
])
for tr, te in walk_forward(len(X)):
    mo_hinh.fit(X.iloc[tr], y.iloc[tr])
    xac_suat = mo_hinh.predict_proba(X.iloc[te])
```

2.5. Phương pháp và chỉ số đánh giá

Chiến lược đánh giá. Giá cổ phiếu là chuỗi thời gian nên không dùng kiểm định chéo K-fold xáo trộn hay `train_test_split` ngẫu nhiên: các mẫu liền kề tương quan và nhãn của mẫu huấn luyện có thể chứa thông tin của giai đoạn kiểm tra, làm kết quả đẹp giả tạo [2, 9]. Walk-forward mô phỏng đúng cách dùng thực tế (huấn luyện bằng quá khứ, dự đoán giai đoạn kế tiếp), cửa sổ mở rộng tận dụng toàn bộ lịch sử, và nhiều fold cho phép đo độ ổn định của mô hình qua các giai đoạn thị trường khác nhau.

Chỉ số. Chỉ riêng Accuracy chưa đủ vì không cho biết mô hình có bỏ sót một lớp nào hay không; vì vậy nhóm dùng thêm F1 macro (đối xử ba lớp như nhau) và ROC-AUC một-đối-còn-lại (đánh giá chất lượng xếp hạng bằng xác suất, không phụ thuộc ngưỡng). Hai chỉ số này được so với mức ngẫu nhiên ($\approx 0{,}33$ cho F1 macro và Accuracy, $0{,}5$ cho ROC-AUC). Vì chỉ số dự đoán tốt chưa chắc dẫn đến lợi nhuận, nhóm bổ sung backtest chỉ mua có phí và thuế, so với mua và nắm giữ. Khi so sánh các mô hình, nhóm xét cả độ lệch chuẩn qua các fold để tránh kết luận từ chênh lệch nhỏ hơn mức dao động.

2.6. Kết luận chương 2

Chương này phát biểu bài toán phân loại ba lớp cho từng mã cổ phiếu, đặt mục tiêu theo các mức tham chiếu, chọn Hồi quy Logistic, Rừng ngẫu nhiên và XGBoost cùng ba mô hình cơ sở, và mô tả quy trình huấn luyện walk-forward không rò rỉ dữ liệu cùng các chỉ số đánh giá. Chương 3 trình bày dữ liệu và kết quả thực nghiệm.

CHƯƠNG 3

THỰC NGHIỆM VÀ ĐÁNH GIÁ

3.1. Dữ liệu thực nghiệm

3.1.1. Nguồn dữ liệu

Dữ liệu nến ngày (OHLCV) của bốn mã TCB, CTG, VNM, ACB được thu thập từ API biểu đồ của DNSE (Entrade), cùng nguồn với bảng giá trực tuyến `https://banggia.dnse.com.vn/v2?symbol=TCB` (tương tự với các mã còn lại). Dữ liệu là giá giao dịch công khai trên sàn, được thu thập bằng mã `crawl.py` của nhóm vào ngày 23/10/2026 và lưu thành các tệp `data/raw/1D/<MÃ>.csv`. Giá tính bằng nghìn đồng, khối lượng tính bằng số cổ phiếu; giá có vẻ đã được điều chỉnh theo chia tách và cổ tức vì không thấy bước nhảy bất thường vượt biên độ sàn.

Đề bài gợi ý khoảng thu thập 6 tháng, tương ứng khoảng 126 phiên. Với chừng đó mẫu, việc huấn luyện và kiểm định walk-forward không đáng tin cậy, nên nhóm dùng toàn bộ lịch sử mà API cung cấp (Bảng 3.1).

Bảng 3.1. Phạm vi dữ liệu nến ngày thô của bốn mã

Mã	Số nến	Từ ngày	Ghi chú
TCB	2 098	04/06/2018	Niêm yết HOSE từ 06/2018
CTG	2 495	26/10/2016	
VNM	2 495	26/10/2016	
ACB	2 492	26/10/2016	Trên HNX (biên độ $\pm 10\%$) đến cuối 2020

Tất cả bốn tệp có chung ngày kết thúc là 23/10/2026. Mỗi tệp có 6 cột và không có giá trị thiếu.

3.1.2. Từ điển dữ liệu thô

Bảng 3.2. Từ điển dữ liệu thô (mỗi dòng là một nến ngày)

STT	Tên cột	Kiểu dữ liệu	Ý nghĩa
1	`time`	Ngày (`YYYY-MM-DD`)	Ngày giao dịch của nến
2	`open`	Số thực	Giá mở cửa (nghìn đồng)
3	`high`	Số thực	Giá cao nhất trong phiên (nghìn đồng)
4	`low`	Số thực	Giá thấp nhất trong phiên (nghìn đồng)
5	`close`	Số thực	Giá đóng cửa (nghìn đồng)
6	`volume`	Số nguyên	Khối lượng khớp lệnh trong phiên (cổ phiếu)

Sau làm sạch, mã `preprocess_data.py` tạo 25 đặc trưng số tại phiên t. Trong Bảng 3.3, C_t, O_t, H_t, L_t, V_t lần lượt là giá đóng cửa, mở cửa, cao nhất, thấp nhất và khối lượng; mọi cửa sổ đều kết thúc tại t.

Bảng 3.3. Từ điển 25 đặc trưng sau tiền xử lý

Tên cột	Công thức	Ý nghĩa
`close_sma5`, `close_sma10`, `close_sma20`	$C_t / \mathrm{SMA}_k(C)_t - 1$, $k \in \{5, 10, 20\}$	Vị trí giá so với trung bình động ngắn và trung hạn
`sma5_sma20`	$\mathrm{SMA}_5 / \mathrm{SMA}_{20} - 1$	Tín hiệu giao cắt trung bình động
`close_ema12`, `close_ema26`	$C_t / \mathrm{EMA}_k(C)_t - 1$, $k \in \{12, 26\}$	Vị trí giá so với trung bình động lũy thừa
`macd`	$(\mathrm{EMA}_{12} - \mathrm{EMA}_{26})/C_t$	Động lượng đã chuẩn hóa theo mức giá
`macd_signal`	$\mathrm{EMA}_9(\texttt{macd})$	Đường tín hiệu của MACD

Tên cột	Công thức	Ý nghĩa
macd_hist	macd – macd_signal	Khoảng cách MACD và đường tín hiệu
rsi14	RSI Wilder 14 phiên chia 100	Động lượng trong khoảng $[0, 1]$
bb_pctb	$(C_t - BB_{lower})/(BB_{upper} - BB_{lower})$	Vị trí giá trong dải Bollinger 20 phiên
bb_width	$(BB_{upper} - BB_{lower})/\,\mathrm{SMA}_{20}$	Độ rộng dải Bollinger, đại diện biến động
ret_1, ret_2, ret_3, ret_5	$\ln(C_t/C_{t-k})$, $k \in \{1, 2, 3, 5\}$	Lợi suất logarit các kỳ gần nhất
body	$(C_t - O_t)/O_t$	Kích thước và chiều thân nến
upper_shadow	$(H_t - \max(O_t, C_t))/C_t$	Độ dài bóng nến trên
lower_shadow	$(\min(O_t, C_t) - L_t)/C_t$	Độ dài bóng nến dưới
hl_range	$(H_t - L_t)/C_t$	Biên độ dao động trong phiên
volat_5, volat_20	Độ lệch chuẩn của ret_1 trong 5 và 20 phiên	Biến động ngắn và trung hạn
vol_ratio	$V_t/\,\mathrm{SMA}_{20}(V)_t$	Khối lượng tương đối so với 20 phiên
vol_chg	$\ln(V_t/V_{t-1})$	Tốc độ thay đổi khối lượng
atr14	$\mathrm{SMA}_{14}(TR)_t/C_t$	Average True Range 14 phiên đã chuẩn hóa theo giá

Trong đó $TR_t = \max(H_t - L_t, |H_t - C_{t-1}|, |L_t - C_{t-1}|)$. Đặc trưng atr14 được bổ sung để đo biến động có xét khoảng trống giá qua đêm, đồng thời giải quyết chênh lệch giữa danh sách 24 đặc trưng ban đầu và thiết kế 25 đặc trưng của báo cáo.

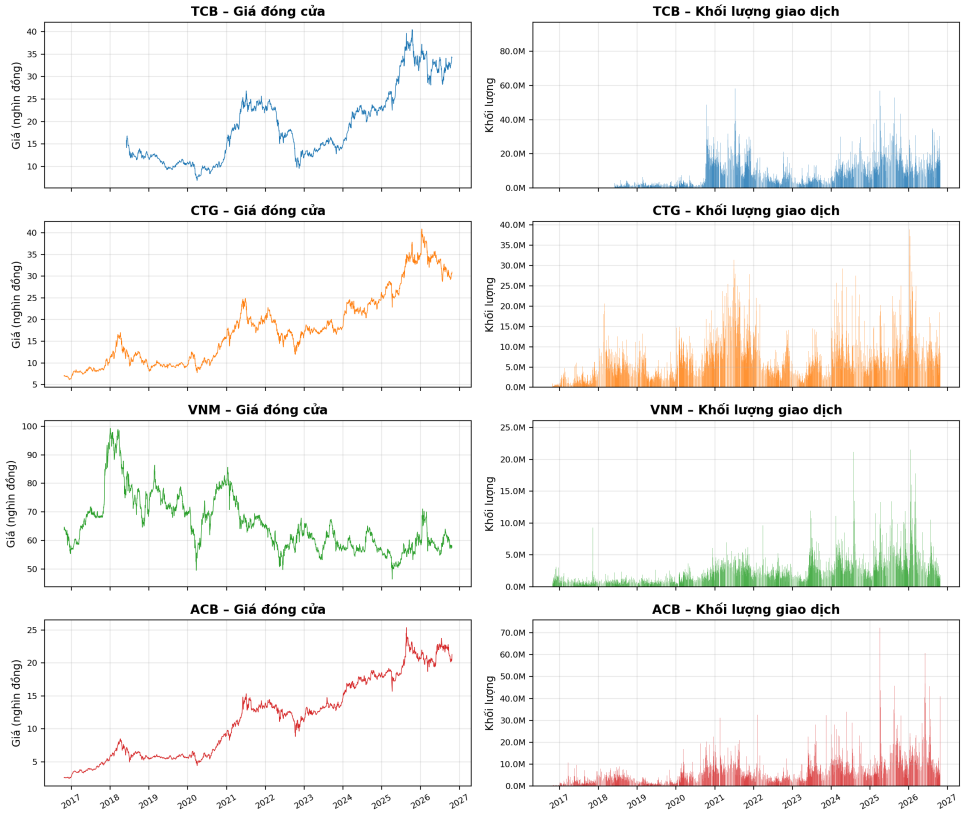
Với các khung nội ngày, nhóm bổ sung năm đặc trưng time_sin, time_cos, weekday_sin, weekday_cos và is_first_bar. Bốn cột sin/cos biểu diễn chu kỳ giờ trong ngày và thứ trong tuần mà không tạo điểm gián đoạn; cờ cuối đánh dấu nến đầu ngày, nơi ret_1 bao gồm khoảng trống giá qua đêm. Vì vậy dữ liệu 1D có 25 đặc trưng, còn mỗi khung nội ngày có 30 đặc trưng.

Tệp đầu ra còn giữ `time` làm chỉ mục, `close` để vẽ và backtest, `r_next` để tính lợi nhuận, cùng `label` là nhãn ba lớp. Hai cột nhìn về tương lai `r_next` và `label` không thuộc danh sách đặc trưng.

3.2. Khảo sát và phân tích dữ liệu

3.2.1. Biến động giá và khối lượng theo thời gian

Hình 3.1 biểu diễn chuỗi giá đóng cửa và khối lượng giao dịch hằng ngày của bốn mã cổ phiếu trong toàn bộ giai đoạn thu thập dữ liệu.



Hình 3.1. Giá đóng cửa và khối lượng giao dịch ngày của bốn mã cổ phiếu

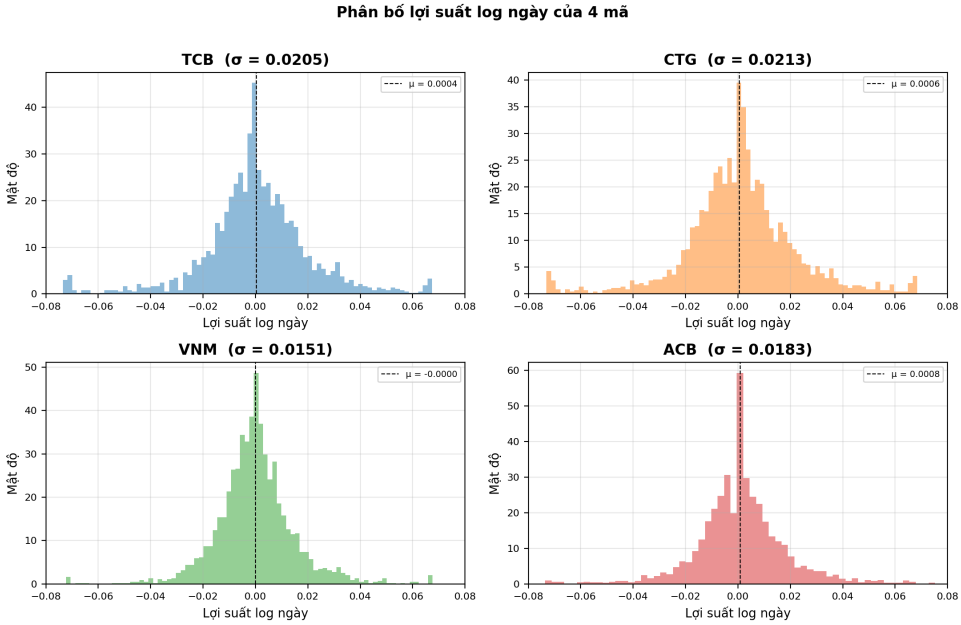
Nhận xét:

- Ba cổ phiếu ngân hàng (TCB, CTG, ACB) có xu hướng tăng trưởng dài hạn rõ rệt từ năm 2017 đến cuối 2026, xen kẽ các chu kỳ điều chỉnh mạnh tương ứng với biến động kinh tế vĩ mô: đợt bán tháo do đại dịch COVID-19 (quý 1/2020) và giai đoạn thắt chặt tín dụng, thanh lọc thị trường trái phiếu doanh nghiệp (nửa cuối 2022). Ngược lại, cổ phiếu tiêu dùng VNM duy trì xu hướng đi ngang và giảm nhẹ sau vùng đỉnh năm 2018.
- Khối lượng giao dịch có xu hướng gia tăng đột biến tại các vùng đáy điều chỉnh và các giai đoạn thị trường đảo chiều (hiện tượng cao trào khối lượng – *volume climax*), phản ánh dòng tiền bắt đáy hoặc phân phối mạnh.
- Tính chất phi dừng (non-stationarity) rõ rệt của giá đóng cửa (trung bình và

phương sai thay đổi liên tục theo thời gian) khẳng định tính đúng đắn của nguyên tắc thiết kế: **không đưa chuỗi giá thô vào mô hình học máy**, mà chuyển hóa thành các tỷ số so với đường trung bình và các chỉ báo kỹ thuật dừng.

3.2.2. Phân bố lợi suất ngày

Hình 3.2 minh họa phân bố tần suất và hàm mật độ của lợi suất logarit ngày $r_t = \ln(C_t/C_{t-1})$ cho từng mã.



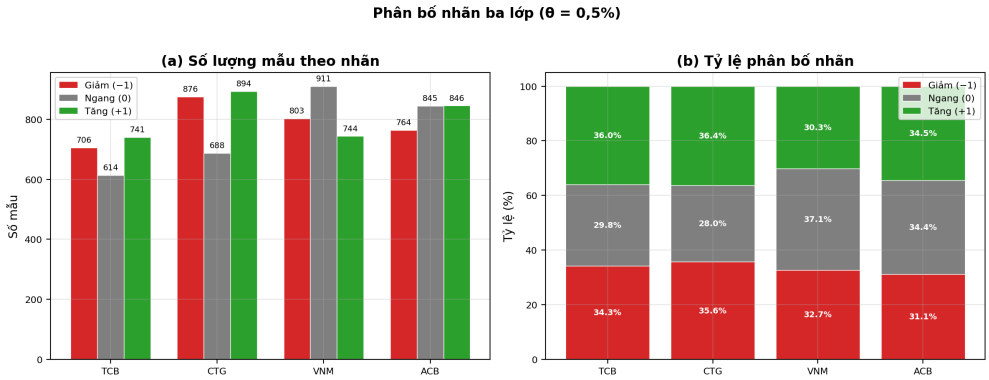
Hình 3.2. Phân bố tần suất lợi suất logarit ngày của bốn mã

Nhận xét:

- Lợi suất ngày của cả bốn mã phân bố gần đối xứng quanh giá trị trung bình xấp xỉ 0 ($\mu \in [0{,}0003;\ 0{,}0007]$), nhưng có dạng nhọn ở đỉnh và đuôi dày (leptokurtic) rõ rệt so với phân phối chuẩn Gauss. Hiện tượng này đặc trưng cho dữ liệu tài chính với tần suất xuất hiện các phiên biến động lớn cao hơn lý thuyết xác suất cổ điển.
- Độ lệch chuẩn lợi suất ngày σ dao động từ $1{,}54\%$ (VNM) đến $2{,}08\%$ (TCB), phản ánh mức độ rủi ro và biên độ dao động của nhóm ngân hàng cao hơn đáng kể so với nhóm hàng tiêu dùng thiết yếu.
- Ngưỡng phân lớp $\theta = 0{,}5\%$ tương ứng với khoảng $0{,}25\sigma$ đến $0{,}33\sigma$, nằm vừa vặn trong vùng biến động thường nhật và tương đương với chi phí giao dịch thực tế (thuế $0{,}1\%$ + phí môi giới hai chiều $0{,}3\%$).

3.2.3. Phân bố nhãn xu hướng

Hình 3.3 thống kê số lượng và tỷ lệ phần trăm của ba lớp nhãn (giảm: -1, ngang: 0, tăng: 1) với ngưỡng $\theta = 0{,}5\%$ trên tập dữ liệu đã tiền xử lý.



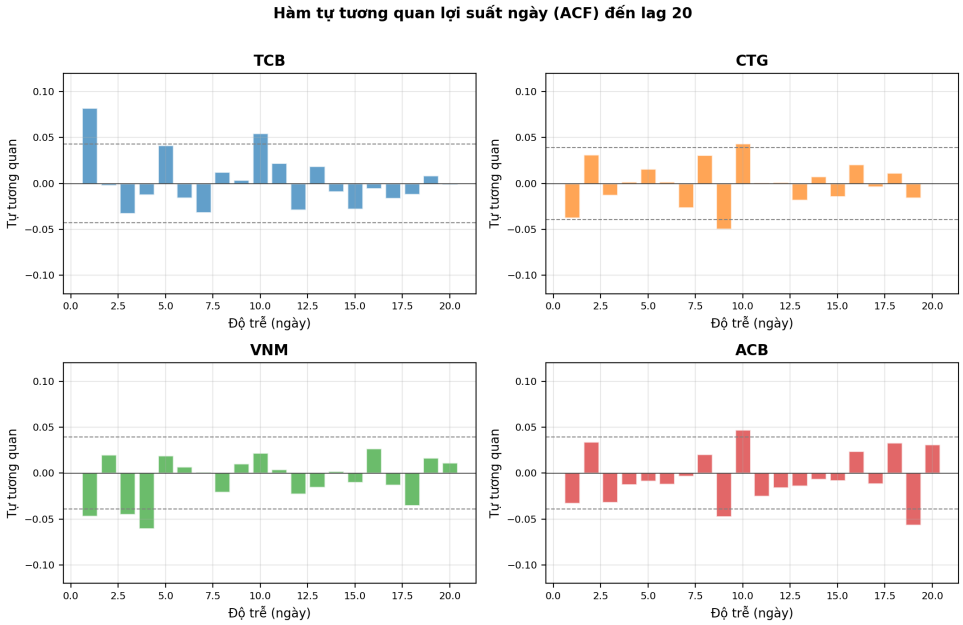
Hình 3.3. Số lượng và tỷ lệ phân bố ba lớp nhãn ($\theta = 0{,}5\%$) sau tiền xử lý

Nhận xét:

- Tỷ lệ ba lớp tương đối cân bằng trên cả bốn mã: lớp giảm chiếm $31{,}1\%$–$35{,}6\%$, lớp ngang chiếm $28{,}0\%$–$37{,}1\%$, và lớp tăng chiếm $30{,}3\%$–$36{,}4\%$. Do độ lệch giữa các lớp không vượt quá 40%, tập dữ liệu không cần áp dụng các kỹ thuật cân bằng nhân tạo như SMOTE hay Random Undersampling (tránh nguy cơ bóp méo phân phối thời gian).
- Mã VNM có tỷ lệ phiên đi ngang cao nhất ($37{,}1\%$), phù hợp với độ biến động thấp đã quan sát ở phân bố lợi suất. Các mã tăng trưởng mạnh như TCB và CTG có tỷ lệ lớp tăng chiếm ưu thế ($36{,}0\%$ và $36{,}4\%$).
- Để đánh giá khách quan hiệu năng trên bài toán ba lớp gần cân bằng này, nhóm lựa chọn F1 macro và ROC-AUC macro làm các thước đo chất lượng chính thay vì chỉ dùng Accuracy.

3.2.4. Tự tương quan của chuỗi lợi suất

Hình 3.4 biểu diễn hệ số tự tương quan (Autocorrelation Function – ACF) của chuỗi lợi suất ngày từ độ trễ 1 đến 20 phiên.



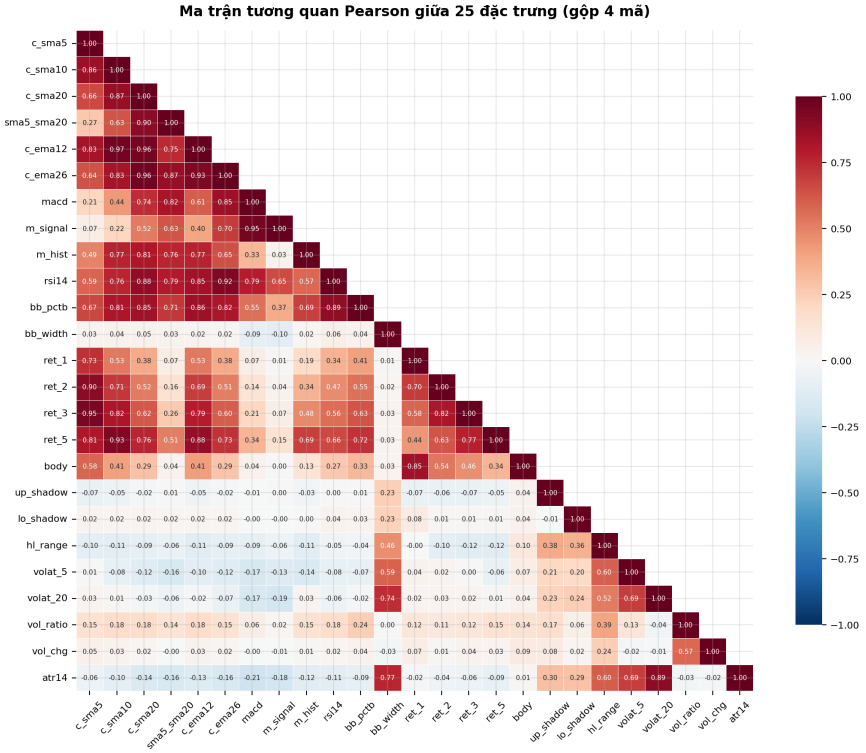
Hình 3.4. Hàm tự tương quan (ACF) của lợi suất ngày đến lag 20 kèm dải tin cậy 95%

Nhận xét:

- Hệ số tự tương quan tại hầu hết các độ trễ đều rất nhỏ ($|r| < 0{,}05$) và nằm hoàn toàn bên trong dải tin cậy 95% ($\pm 1{,}96/\sqrt{n}$, biểu thị bằng đường nét đứt xám).
- Kết quả này hoàn toàn nhất quán với Giả thuyết thị trường hiệu quả dạng yếu (Weak-form EMH) của Fama [5]: lợi suất phiên kế tiếp không có quan hệ tuyến tính trực tiếp với lợi suất các phiên quá khứ gần nhất.
- Điều đó giải thích vì sao các mô hình tuyến tính đơn giản chỉ dùng độ trễ giá thường thất bại, và đặt ra sự cần thiết phải tích hợp các chỉ báo động lượng, xu hướng và biến động phi tuyến, cùng các thuật toán phi tuyến tính như Rừng ngẫu nhiên và XGBoost.

3.2.5. Quan hệ tương quan giữa các đặc trưng

Hình 3.5 trình bày ma trận tương quan Pearson giữa 25 đặc trưng sau khi chuẩn hóa, được tính toán trên toàn bộ dữ liệu gộp của bốn mã cổ phiếu.



Hình 3.5. Ma trận tương quan Pearson giữa 25 đặc trưng số (gộp 4 mã)

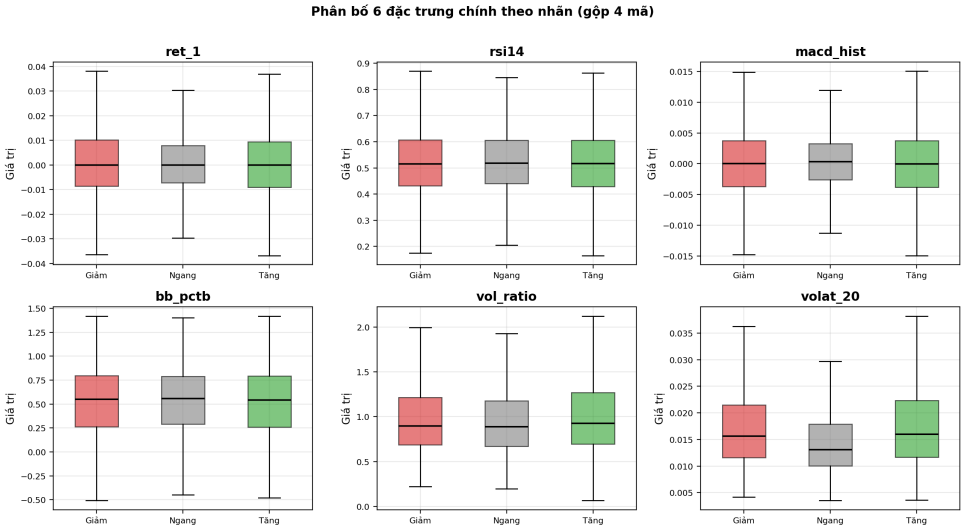
Nhận xét:

1. **Cụm đặc trưng xu hướng và vị thế giá:** Các đặc trưng đo khoảng cách giữa giá đóng cửa và các đường trung bình động (`close_sma5`, `close_sma10`, `close_sma20`, `close_ema12`, `close_ema26`) có hệ số tương quan thuận rất cao ($r > 0{,}80$). Đặc biệt, `bb_pctb` (vị trí tương đối trong dải Bollinger) có tương quan lên tới $0{,}95$ với `close_sma20` do cùng sử dụng trung bình động 20 phiên làm trục cơ sở.
2. **Cụm đặc trưng độ biến động:** `volat_5`, `volat_20`, `hl_range`, `bb_width` và `atr14` tạo thành một nhóm có tương quan dương rõ rệt ($r \in [0{,}55;\ 0{,}85]$), cùng phản ánh trạng thái dao động mạnh hay hẹp của thị trường trong phiên.
3. **Tính độc lập của tín hiệu khối lượng:** Các đặc trưng liên quan đến khối lượng (`vol_ratio`, `vol_chg`) có mức độ tương quan tuyến tính rất thấp với các đặc trưng giá và biến động ($|r| < 0{,}15$), chứng minh khối lượng mang lại nguồn thông tin bổ trợ trực giao, không bị trùng lặp với hành động giá.
4. **Ý nghĩa với mô hình hóa:** Hiện tượng đa cộng tuyến giữa các chỉ báo xu hướng đòi hỏi Hồi quy Logistic phải sử dụng chuẩn hóa L_2 (Ridge penalty) để ổn định trọng số; trong khi các thuật toán cây như Rừng ngẫu nhiên và XGBoost vốn có cơ chế chọn ngẫu nhiên tập con đặc trưng (feature subsampling) nên sẽ ít bị tổn

hại bởi hiện tượng này.

3.2.6. Phân bố các đặc trưng chính theo nhãn xu hướng

Hình 3.6 trình bày biểu đồ hộp (boxplot) của sáu đặc trưng đại diện cho ba nhóm (lợi suất, động lượng, biến động) phân theo ba lớp nhãn -1, 0 và 1.



Hình 3.6. Phân bố 6 đặc trưng đại diện theo ba lớp nhãn xu hướng (gộp 4 mã)

Nhận xét:

- `ret_1` thể hiện sự dịch chuyển trung vị rõ nét nhất giữa các lớp: phiên trước tăng thường đi kèm với xu hướng phân loại nhất định, tuy nhiên khoảng tứ phân vị (IQR) giữa ba lớp vẫn chồng lấn đáng kể, khẳng định bài toán có độ nhiễu cao và không thể phân loại bằng một ranh giới đơn biến tầm thường.
- Chỉ báo động lượng `rsi14` và `macd_hist` có phân bố lệch nhẹ sang giá trị cao hơn ở lớp tăng (1) và thấp hơn ở lớp giảm (-1), thể hiện tín hiệu động lượng có giá trị dự báo nhưng cần được kết hợp với các bộ lọc phụ trợ.
- Các đặc trưng biến động (`volat_20`) và khối lượng (`vol_ratio`) có hình dạng phân phối tương đồng giữa ba nhãn; vai trò của chúng trong mô hình không phải là yếu tố phân tách tuyến tính trực tiếp mà là các điều kiện kích hoạt phi tuyến trong cây quyết định (ví dụ: chỉ báo RSI hiệu quả hơn trong môi trường biến động thấp).

3.3. Phát hiện và xử lý vấn đề chất lượng dữ liệu

Bảng 3.4 tổng hợp các vấn đề đã kiểm tra trên dữ liệu thô của bốn mã và cách xử lý đã được cài đặt trong `clean_data.py`.

Bảng 3.4. Thống kê các vấn đề chất lượng dữ liệu và cách xử lý

Vấn đề	Số lượng (tỷ lệ)	Cách xử lý và lý do
Giá trị thiếu	0	Không cần xử lý. Nếu xuất hiện thì bỏ dòng, không nội suy vì giá là dữ liệu quan sát thực
Khối lượng bằng 0	0	Nếu có thì bỏ dòng (ngày không giao dịch)
Bản ghi trùng ngày	1 ngày (27/12/2022) tách thành 2 nến ở cả 4 mã	Gộp: `open` của nến đầu, `high` lớn nhất, `low` nhỏ nhất, `close` của nến cuối, `volume` cộng dồn. Đây là lỗi nguồn nên giữ cả hai nến sẽ tạo lợi suất sai
OHLC sai logic (`open`/`close` ngoài $[\texttt{low}, \texttt{high}]$)	3 nến: TCB 18/07/2019; VNM 15/07/2019 và 30/08/2019	Kẹp lại $\texttt{high} = \max(o, h, c)$, $\texttt{low} = \min(o, l, c)$ để giữ nguyên số nến
Biến động bất thường	ACB có 12 phiên $> 7{,}5\%$ đến 06/2020	Giữ nguyên: đều nằm trong biên $\pm 10\%$ của HNX nên là biến động thật
Nến chưa đóng	0 (nến cuối là 23/10/2026)	Bỏ nến của ngày hiện tại nếu thu thập trước 15:00
Mất cân bằng lớp (giảm / ngang / tăng, $\theta = 0{,}5\%$)	TCB 706/614/741; CTG 876/688/894; VNM 803/911/744; ACB 764/845/846	Ba lớp gần cân bằng nên không cần lấy mẫu lại; đánh giá bằng F1 macro và ROC-AUC macro thay vì chỉ Accuracy

Vấn đề	Số lượng (tỷ lệ)	Cách xử lý và lý do
Nguy cơ rò rỉ dữ liệu	Hai cột nhìn về tương lai: `label`, `r_next`	Không đưa vào đặc trưng; chia dữ liệu theo thời gian, bỏ 1 phiên giữa train và test, scaler chỉ fit trên tập train của từng fold

Bảng 3.5. So sánh số nến trước và sau làm sạch dữ liệu 1D

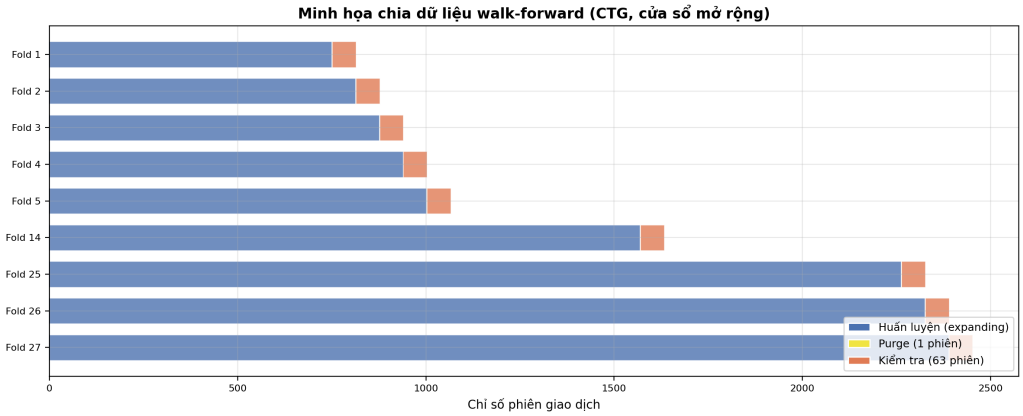
Mã	Trước	Gộp trùng	Sửa OHLC	Sau
TCB	2 098	1	1	2 097
CTG	2 495	1	0	2 494
VNM	2 495	1	2	2 494
ACB	2 492	1	0	2 491

Sau làm sạch, cả bốn tệp không còn giá trị thiếu, ngày trùng, volume không dương hoặc nến vi phạm quan hệ OHLC. Các phiên biến động mạnh hợp lệ vẫn được giữ nguyên.

3.4. Chuẩn bị dữ liệu cho mô hình

Toàn bộ 25 đặc trưng đều là số nên không cần mã hóa biến phân loại; nhãn $\{-1, 0, 1\}$ chỉ được ánh xạ thành $\{0, 1, 2\}$ khi huấn luyện XGBoost. Việc chuẩn hóa chỉ áp dụng cho Hồi quy Logistic bằng `StandardScaler`, được khớp trên tập huấn luyện của từng fold rồi áp dụng cho khối kiểm tra của fold đó; Rừng ngẫu nhiên và XGBoost không cần chuẩn hóa. Dữ liệu không được xáo trộn mà chia theo thời gian bằng walk-forward như ở Mục 2.4.

Hình 3.7 minh họa trực quan cấu trúc các fold kiểm định walk-forward thực tế được tạo ra cho mã CTG (27 fold). Cơ chế cửa sổ mở rộng (expanding window) giúp tập huấn luyện tích lũy dữ liệu lịch sử theo thời gian, khối kiểm tra 63 phiên liền kề không chồng lấn, và khoảng cách ly (purge) 1 phiên được duy trì nghiêm ngặt giữa tập huấn luyện và kiểm tra nhằm ngăn chặn việc nhãn phiên cuối của tập train sử dụng giá đóng cửa phiên đầu của tập test.



Hình 3.7. Minh họa các fold kiểm định walk-forward thực tế trên mã CTG (27 fold)

Sau khi bỏ 35 phiên khởi động (do chỉ báo dài nhất cần EMA26 rồi EMA9) và phiên cuối không có nhãn, mã tiền xử lý tạo ra kích thước dữ liệu thực tế ở Bảng 3.6.

Bảng 3.6. Kích thước dữ liệu đã tiền xử lý và số fold walk-forward

Mã	Số mẫu	Số đặc trưng	Train đầu	Test/fold	Số fold
TCB	2 061	25	750	63	20
CTG	2 458	25	750	63	27
VNM	2 458	25	750	63	27
ACB	2 455	25	750	63	27

Các tệp đầu ra bắt đầu từ 23/07/2018 đối với TCB và 14/12/2016 đối với ba mã còn lại; ngày cuối có nhãn là 22/10/2026. Số liệu chi tiết và phân bố nhãn được lưu tại `data/processed/1D/preprocessing_summary.csv`.

Ngoài khung chính 1D, quy trình đã tạo dữ liệu sẵn sàng cho thí nghiệm ở năm khung nội ngày. Ngưỡng nhãn được chọn theo độ biến động và bước giá thực tế trước khi huấn luyện; mỗi khung vẫn dùng ba lớp giảm, ngang và tăng.

Bảng 3.7. Quy tắc và kết quả tiền xử lý theo khung nến

Khung	θ	Đặc trưng	Tổng mẫu	Train đầu	Test/fold	Fold/mã
1 phút	0,05%	30	56 377	9 000	1 125	4
5 phút	0,10%	30	11 448	1 800	225	4
15 phút	0,15%	30	3 888	640	80	4
30 phút	0,15%	30	2 124	315	45	4
1 giờ	0,20%	30	9 787	1 000	125	11
1 ngày	0,50%	25	9 432	750	63	20–27

Khung 1 phút có 57,4% nến thuộc lớp ngang do nhiều nến không đổi giá; giảm ngưỡng không khắc phục được hiện tượng này vì bước giá rời rạc. Nhóm giữ nguyên dữ liệu, không lấy mẫu lại trước khi chia thời gian, và sẽ dùng F1 macro để tránh chỉ số bị chi phối bởi lớp ngang. Các khung còn lại có tỷ lệ lớp phù hợp để tiếp tục huấn luyện mà không cần tái lấy mẫu.

3.5. Môi trường thực nghiệm

Toàn bộ quy trình từ thu thập, làm sạch dữ liệu, trích xuất đặc trưng đến huấn luyện và kiểm định mô hình được thực hiện trên môi trường điện toán cá nhân với thông số phần cứng và phiên bản phần mềm được liệt kê tại Bảng 3.8.

Bảng 3.8. Môi trường thực nghiệm phần cứng và phần mềm

Thành phần	Cấu hình / Phiên bản	Mục đích sử dụng
Hệ điều hành	Windows 11 Pro 64-bit	Nền tảng thực thi
Bộ vi xử lý (CPU)	Multi-core Processor (x86_64)	Xử lý tính toán song song
Bộ nhớ trong (RAM)	16 GB	Lưu trữ và xử lý mảng dữ liệu
Môi trường thực thi	Python 3.11.9 (`.venv`)	Phiên bản ngôn ngữ chính
`numpy`	2.0.2	Xử lý mảng và đại số tuyến tính
`pandas`	2.2.3	Xử lý chuỗi thời gian và DataFrame
`scikit-learn`	1.5.2	Pipeline, Logistic Regression, Random Forest
`xgboost`	2.1.3	Mô hình phân loại Gradient Boosting
`matplotlib`	3.9.2	Vẽ biểu đồ phân bố và xu hướng
`seaborn`	0.13.2	Vẽ ma trận tương quan (heatmap)

Để đảm bảo tính tái lập (reproducibility) của toàn bộ thực nghiệm, tham số hạt giống ngẫu nhiên được cố định nghiêm ngặt `random_state = 42` ở tất cả các thành phần có tính ngẫu nhiên (chia mẫu, khởi tạo tham số mô hình, lấy mẫu đặc trưng và túi con trong Random Forest và XGBoost). Hướng dẫn thiết lập môi trường và chạy lại toàn bộ mã nguồn được trình bày chi tiết trong Phụ lục A.

3.6. Kết quả huấn luyện và đánh giá

[Hướng dẫn: Báo cáo giá trị trung bình ± độ lệch chuẩn qua các fold. Tập kiểm tra chỉ dùng cho đánh giá cuối cùng.]

Bảng 3.9. So sánh kết quả kiểm định walk-forward của các mô hình

Mô hình	F1-score	ROC-AUC	Thời gian (s)
Cơ sở (lớp đa số)	$0{,}000 \pm 0{,}000$	$0{,}500 \pm 0{,}000$	…
Hồi quy Logistic	…	…	…
Rừng ngẫu nhiên	…	…	…
XGBoost	…	…	…



Hình 3.8. Ma trận nhầm lẫn của mô hình tốt nhất trên tập kiểm định

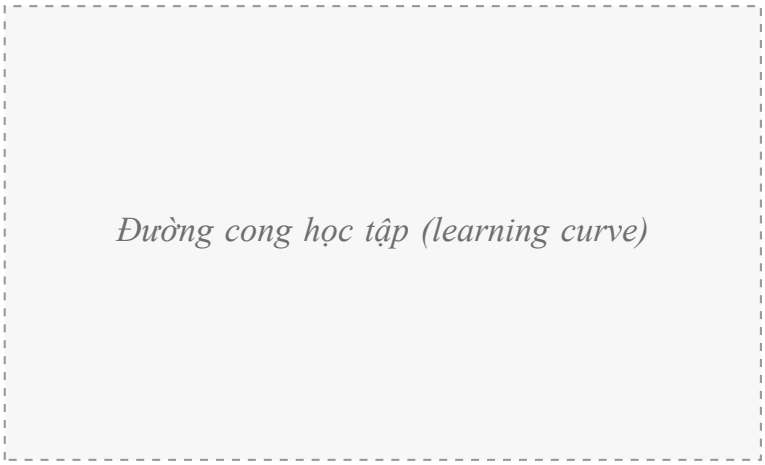
3.7. Phân tích kết quả dự đoán

[Hướng dẫn: Phân tích lỗi: nhóm mẫu dự đoán sai nhiều; so sánh kết quả trên tập huấn luyện và kiểm định để nhận diện quá khớp/chưa khớp; giải thích vì sao mô hình này tốt/kém hơn mô hình kia; các đặc trưng ảnh hưởng nhiều.]

3.8. Tối ưu hóa và cải tiến mô hình

3.8.1. Phân tích hạn chế của mô hình ban đầu

[Hướng dẫn: Chỉ ra hạn chế dựa trên bằng chứng: chênh lệch huấn luyện – kiểm định, đường cong học tập, lỗi tập trung ở nhóm dữ liệu cụ thể…]



Hình 3.9. Đường cong học tập của mô hình ban đầu

3.8.2. Cải tiến dữ liệu và đặc trưng

[Hướng dẫn: Thiết kế đặc trưng mới, lựa chọn đặc trưng, giảm chiều, xử lý mất cân bằng…và đo tác động.]

3.8.3. Thử nghiệm thuật toán hoặc cấu hình khác

[Hướng dẫn: Thử thuật toán mới hoặc phương pháp tổ hợp (Bagging, Boosting, Voting/Stacking…).]

3.8.4. Tối ưu hóa siêu tham số

[Hướng dẫn: Tìm kiếm bằng Grid/Random Search hoặc Bayesian Optimization trên kiểm định chéo; không dùng tập kiểm tra để chọn siêu tham số.]

Bảng 3.10. Không gian tìm kiếm và giá trị siêu tham số tối ưu

Siêu tham số	Không gian tìm kiếm	Giá trị tối ưu
`n_estimators`	$\{100, 300, 500\}$	…
`max_depth`	$\{5, 10, 20, \text{None}\}$	…
…	…	…

3.9. So sánh trước và sau cải tiến

[Hướng dẫn: Bảng so sánh cùng dữ liệu, cùng cách chia, cùng chỉ số; thể hiện

đóng góp của từng thay đổi (ablation).]

Bảng 3.11. Đóng góp của từng cải tiến (ablation)

Cấu hình	F1-score (CV)	Thay đổi
Mô hình ban đầu	…	–
+ Đặc trưng mới	…	…
+ Xử lý mất cân bằng	…	…
+ Tối ưu siêu tham số	…	…

Biểu đồ so sánh các mô hình
(có nhãn trục, đơn vị)

Hình 3.10. So sánh chỉ số đánh giá của các mô hình trước và sau cải tiến

3.10. Khả năng tổng quát hóa và lựa chọn mô hình cuối

3.10.1. Khả năng tổng quát hóa

[Hướng dẫn: Đánh giá mô hình cuối trên tập kiểm tra giữ lại; so sánh với kết quả kiểm định chéo; nhận xét độ ổn định qua các fold/lần chạy.]

3.10.2. Lựa chọn mô hình cuối cùng

[Hướng dẫn: Lựa chọn dựa trên đánh đổi giữa độ chính xác, độ ổn định, thời gian và khả năng diễn giải; giải thích vì sao cải tiến có/không hiệu quả.]

3.11. Kết luận chương 3

[Hướng dẫn: Tóm tắt kết quả chính của chương.]

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

1. Kết quả đạt được

[Hướng dẫn: Tóm tắt các kết quả chính so với mục tiêu đặt ra ở phần Mở đầu, kèm số liệu cụ thể của mô hình cuối.]

2. Hạn chế

[Hướng dẫn: Các hạn chế còn tồn tại về dữ liệu, mô hình, phương pháp đánh giá.]

3. Hướng phát triển

[Hướng dẫn: Các hướng phát triển khả thi trong tương lai.]

TÀI LIỆU THAM KHẢO

[1] Trương Thị Thùy Dương (2023), "Dự báo chiều biến động của chỉ số chứng khoán bằng thuật toán tăng cường", *Tạp chí Khoa học và Đào tạo Ngân hàng*, số 252, tr. 25–37.

[2] C. Bergmeir, J. M. Benítez (2012), "On the use of cross-validation for time series predictor evaluation", *Information Sciences*, vol. 191, pp. 192–213.

[3] L. Breiman (2001), "Random forests", *Machine Learning*, vol. 45, no. 1, pp. 5–32.

[4] T. Chen, C. Guestrin (2016), "XGBoost: A scalable tree boosting system", in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794.

[5] E. F. Fama (1970), "Efficient capital markets: A review of theory and empirical work", *The Journal of Finance*, vol. 25, no. 2, pp. 383–417.

[6] T. Hastie, R. Tibshirani, J. Friedman (2009), *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed., Springer, New York.

[7] Y. Kara, M. A. Boyacioglu, Ö. K. Baykan (2011), "Predicting direction of stock price index movement using artificial neural networks and support vector machines: The sample of the Istanbul Stock Exchange", *Expert Systems with Applications*, vol. 38, no. 5, pp. 5311–5319.

[8] C. Krauss, X. A. Do, N. Huck (2017), "Deep neural networks, gradient-boosted trees, random forests: Statistical arbitrage on the S&P 500", *European Journal of Operational Research*, vol. 259, no. 2, pp. 689–702.

[9] M. López de Prado (2018), *Advances in Financial Machine Learning*, Wiley, Hoboken.

[10] J. Patel, S. Shah, P. Thakkar, K. Kotecha (2015), "Predicting stock and stock price index movement using trend deterministic data preparation and machine learning techniques", *Expert Systems with Applications*, vol. 42, no. 1, pp. 259–268.

[11] F. Pedregosa *et al.* (2011), "Scikit-learn: Machine learning in Python", *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830.

[12] J. W. Wilder (1978), *New Concepts in Technical Trading Systems*, Trend Research, Greensboro.

PHỤ LỤC A

HƯỚNG DẪN CÀI ĐẶT VÀ CHẠY CHƯƠNG TRÌNH

A.1. Yêu cầu môi trường

- Python $\geq$ 3.10; các thư viện liệt kê trong `requirements.txt`.
- Mã nguồn: `https://github.com/ductoan10th11/stock`.

A.2. Các bước thực hiện

Từ thư mục gốc của dự án, tạo môi trường, cài thư viện, làm sạch toàn bộ sáu khung nến rồi tạo tập đặc trưng và nhãn cho khung 1D bằng các lệnh sau:

```
python -m venv .venv
.venv/Scripts/python -m pip install -r requirements.txt
.venv/Scripts/python clean_data.py
.venv/Scripts/python preprocess_data.py
```

Các tệp trung gian được ghi vào `data/cleaned/<KHUNG>/`; tập sẵn sàng cho mô hình được ghi vào `data/processed/<KHUNG>/`. Hai loại tệp `cleaning_summary.csv` và `preprocessing_summary.csv` lưu số dòng trước–sau để kiểm tra khả năng chạy lại. Các lệnh huấn luyện, đánh giá và demo sẽ được bổ sung khi các mô-đun tương ứng hoàn thành.